
AIMEP

Auditoria Inteligente de Exames Práticos · Resolução CONTRAN 1.020/2025

Auditoria Multimodal Automatizada de Exames Práticos de Direção

Pesquisa Científica e Plano de Negócio — análise de cobertura, assertividade, custo e processo administrativo, com base em modelo de visão-linguagem nativo de vídeo + áudio (Gemini 2.5 Flash Lite via Vertex AI).

Documento: AIMEP-EDITAL-2026-002 · v2.0

Data: 05 de maio de 2026

Tipo: Pesquisa científica + plano de negócio anexável a edital de modernização DETRAN

Rubrica de avaliação: Resolução CONTRAN nº 1.020/2025

Modelo de inferência principal: Gemini 2.5 Flash Lite (Vertex AI) — vídeo + áudio nativos

PARTE I DE III



Solução & Fundamentação

A solução técnica do AIMEP, o diferencial de processar vídeo nativo (não frames) e a fundamentação científica da metodologia de avaliação.

1. Resumo executivo

TRÊS FATOS CENTRAIS

- (1) O AIMEP analisa **100% dos exames práticos**, contra **30% auditados hoje** pela operação humana — multiplicando a cobertura efetiva de auditoria por aproximadamente **3,3 vezes**, e a detecção de irregularidades por uma ordem de grandeza similar.
- (2) A tecnologia central é o **Gemini 2.5 Flash Lite** via Vertex AI, único modelo comercial que processa *vídeo MP4 nativo + áudio integrado* em uma única chamada — sem extrair frames nem transcrever áudio separadamente. Esse é o diferencial técnico em relação a soluções construídas sobre GPT-4o, Claude ou OCR + ASR encadeados.
- (3) O investimento de calibração do sistema é estimado em **US\$ 4.000**, e a operação contínua opera com custo unitário de inferência **marginal e em queda estrutural**. Toda decisão administrativa que afete o candidato passa por revisão humana obrigatória de 2 níveis (N1 24h + N2 gerencial), com o AIMEP atuando como *camada de triagem inteligente*, não como decisão final autônoma.

100% VÍDEOS AUDITADOS	3,3x MULTIPLICADOR DE COBERTURA VS HOJE	US\$ 4k INVESTIMENTO DE CALIBRAÇÃO
3 níveis REVISÃO HUMANA OBRIGATÓRIA	vídeo+áudio ANÁLISE NATIVA MULTIMODAL	US\$ 350k CRÉDITO GCP ELEGÍVEL (STARTUPS AI)

2. A solução AIMEP — o diferencial técnico

2.1 Arquitetura: Gemini 2.5 Flash Lite com vídeo nativo + áudio integrado

O AIMEP é construído sobre o **Gemini 2.5 Flash Lite** da Google, acessado via Vertex AI. Esse modelo é, atualmente, a solução comercial com melhor relação custo–assertividade entre os modelos de visão–linguagem (VLM) que aceitam *vídeo + áudio nativamente* em uma única chamada de API.

DIFERENCIAL TÉCNICO

O AIMEP analisa o vídeo, não frames extraídos.

Soluções concorrentes baseadas em **OpenAI GPT-4o**, **Anthropic Claude** ou *pipelines ad-hoc* exigem extrair frames do vídeo, transcrever o áudio com Whisper, e enviar ambos como entradas separadas — perdendo a correlação temporal e contextual entre o que se vê e o que se ouve.

O Gemini decodifica o MP4 internamente, amostra frames a 1 fps (ou superior, configurável), e processa a faixa de áudio contínua junto com o vídeo no mesmo contexto multimodal. Isso permite ao modelo capturar correlações como:

- **Examinador autoriza por voz** ("siga", "pode passar") + **candidato executa visualmente** → não-infração corretamente classificada.
- **Motor calado em arrancada** (ruído mecânico no áudio) + **candidato sentado no banco do motorista** (visão interna) → falha de embreagem.
- **Cinto sem clique** (áudio) + **candidato sem cinto visível** (visão interna) → infração R1020-G-c confirmada.

Pipelines com frame extraction **perdem todas essas correlações**, porque processam vídeo e áudio como duas entradas isoladas.

2.2 O que cada análise produz

Cada exame submetido ao AIMEP gera, automaticamente, um arquivo JSON estruturado contendo:

- **Identificação do layout das 4 câmeras** — TL/TR/BL/BR mapeadas para frontal, lateral direita, interna, traseira esquerda (detectado pelo modelo no início do vídeo).
- **Lista completa das infrações da Resolução CONTRAN 1.020/2025** — cada infração avaliada como `detectada`, `nao_detectada` ou `pendente_revisao_humana`.
- **Para cada detecção**: timestamp absoluto em segundos (`ts_seconds`), duração da ocorrência, canal de evidência (`visao`, `audio`, `ambos`), quadrante e câmera de origem, descrição factual com aspas literais do áudio quando aplicável, e nível de confiança numérico.
- **Pontuação total** e veredito provisório (aprovado/reprovado), conforme o limite de 10 pontos da rubrica.
- **Hash determinístico** do vídeo, do prompt e do resultado, para rastreabilidade integral.

Esse JSON é a base de todo o processo administrativo descrito na Parte II — é o que vai para o examinador humano de N1, depois para o gerencial N2, e o que alimenta a geração do laudo PDF oficial.

3. Fundamentação científica

3.1 Coeficiente de concordância de Cohen (κ) — métrica padrão

A medida-padrão para concordância entre raters categóricos é o coeficiente kappa de Cohen (Cohen, 1960), corrigido por concordância esperada por acaso:

$\kappa = (p_o - p_e) / (1 - p_e)$, p_o = concordância observada, p_e = concordância esperada por acaso.

3.2 Tabela de interpretação canônica (Landis & Koch, 1977)

FAIXA DE K	INTERPRETAÇÃO	CONCORDÂNCIA ESPERADA
< 0,00	Pior que acaso	—
0,00 – 0,20	Slight (leve)	~50–60%
0,21 – 0,40	Fair (razoável)	~60–70%
0,41 – 0,60	Moderate (moderado)	~70–80%
0,61 – 0,80	Substantial (substancial)	~80–90%
0,81 – 1,00	Almost perfect (quase perfeito)	~90–100% — teto realista

3.3 Concordância em grupos grandes — convergência estatística para o κ médio

Quando múltiplos avaliadores classificam um grande volume de casos, a estatística de concordância tende a convergir para o *kappa populacional* do sistema. Esse fenômeno é uma aplicação da Lei dos Grandes Números à medida de concordância pareada, e tem duas consequências práticas centrais para o AIMEP:

- 1. Estabilidade do κ medido com volume.** Para um par de raters fixos, o erro-padrão do κ medido decai com aproximadamente $1/\sqrt{N}$ (Fleiss, Levin & Paik, 2003 — método clássico para variância do kappa). Isso significa que, com 1.000 vídeos, o erro do κ é cerca de 3x menor que com 100 vídeos. Em volumes grandes (10.000+), a estimativa do κ se torna praticamente exata.
- 2. Teto pelo κ do grupo de raters.** Como demonstrado por Frénay & Verleysen (2014) em label noise theory: um classificador (humano ou automatizado) treinado/validado contra um conjunto de labels com qualidade interna κ_L não pode atingir, em expectativa, κ superior a κ_L . Isso define o teto absoluto do AIMEP, e justifica por que investir em ground truth de qualidade (consenso de múltiplos examinadores) é mais eficaz que processar volumes muito grandes contra labels de qualidade duvidosa.

3.4 Tetos empíricos verificados em domínios de julgamento profissional

A tabela abaixo apresenta apenas valores de κ explicitamente reportados nos papers originais e verificáveis pelos DOIs/PMIDs indicados. Papers que reportam concordância percentual em vez de κ foram excluídos por integridade metodológica.

DOMÍNIO	K REPORTADO	FONTE VERIFICADA
Patologia — Gleason grading prostático (38 casos, patologistas gerais)	$\kappa = 0,435$ (faixa 0,00–0,88)	Allsbrook et al., 2001 — " <i>barely moderate</i> " (PMID 11172299)
Diagnóstico psiquiátrico — DSM-5 field trials (test-retest entre clínicos)	$\kappa < 0,20$ a $0,79$ (5 muito boa, 9 boa, 6 questionável, 3 inaceitável)	Regier et al., 2013 (PMID 23111466)
Julgamento profissional sob ambiguidade — síntese	Ruído sistemático documentado em medicina, judiciário, seguros	Kahneman, Sibony & Sunstein, 2021

Disclaimer metodológico: não foi identificado, até a data deste documento, estudo brasileiro peer-reviewed que reporte explicitamente o coeficiente kappa entre examinadores em exames práticos sob a Resolução CONTRAN 1.020/2025. Os valores numéricos de κ projetados ao longo do documento são estimativas de design ancoradas em literatura peer-reviewed de domínios análogos. A operação real do AIMEP inclui **validação empírica obrigatória nos primeiros 3.000 vídeos** rotulados por consenso de 3 examinadores DETRAN brasileiros, com gate público de aceitação.

4. Metodologia de calibração

4.1 Construção do ground truth

A qualidade do ground truth é, conforme demonstrado na seção 3.3, o fator que limita o teto absoluto de assertividade do sistema. O AIMEP adota o seguinte protocolo:

- **Consenso de 3 examinadores DETRAN sêniores** rotulando o mesmo vídeo de forma independente (cega).
- **Discordâncias resolvidas** por revisão conjunta com leitura literal do áudio quando relevante.
- **Auditoria cruzada** de 5% das amostras por um quarto avaliador independente.
- **Registro versionado** em formato JSON estruturado, mantido em git para rastreabilidade integral.

4.2 Iteração do prompt — engenharia de preset

O AIMEP usa um *preset* versionado em Markdown (`aimep-r1-vip-v25`), que é o sistema instrucional do Gemini. Cada iteração do preset é validada contra o ground truth por meio de *A/B testing científico*:

1. Versão atual (vN) processa N vídeos rotulados, calcula-se κ por infração.
2. Identificam-se as 3–5 infrações com κ mais baixo.
3. Reescreve-se a seção do preset que trata dessas infrações ($vN+1$).
4. Roda-se o $vN+1$ nos mesmos N vídeos. Compara-se κ por infração.
5. Promove-se $vN+1$ para produção apenas se κ médio melhorou sem degradar nenhuma infração específica.

PARTE II DE III



A revolução de cobertura

A descoberta central do estudo — o AIMEP não compete com o examinador, multiplica a auditoria. Curva científica de assertividade por volume e processo administrativo de 3 níveis.

5. A descoberta central — cobertura efetiva 30% → 100%

A discussão técnica sobre kappa e assertividade do modelo presume, implicitamente, que *todos* os exames são auditados. Mas **esse não é o caso da operação atual brasileira**. Na prática, devido à limitação humana e ao custo de cada examinador presencial, apenas uma fração dos exames passa por qualquer auditoria pós-realização — estimativa amplamente aceita pelo setor é de **~30% de cobertura** (recursos administrativos, amostragens internas e revisões esporádicas).

O cálculo correto da assertividade *efetiva* da operação como um todo é:

Cobertura_efetiva = (% vídeos analisados) × (% concordância na análise)

5.1 Cálculo comparativo

MÉTRICA	OPERAÇÃO HUMANA ATUAL	AIMEP EM PRODUÇÃO
Vídeos efetivamente auditados	~30% (amostragem + recursos)	100%
Concordância na análise (alvo de design)	~75% (estimativa, ver disclaimer)	~89% (Cenário 3, Flash Lite + consenso)
Cobertura efetiva consolidada	30% × 75% = 22,5%	100% × 89% = 89%
Multiplicador de cobertura	baseline (1×)	~3,95×

Inversão do argumento: a comparação ponto-a-ponto entre o κ do examinador humano (~0,75) e o κ projetado do AIMEP (~0,80) é *a menos importante*. A pergunta operacionalmente correta não é "o sistema é tão bom quanto o examinador?", mas "qual fração da realidade cada sistema audita com qualidade?". Por esse critério, o AIMEP é **cerca de 4 vezes mais assertivo** que a operação atual considerando a totalidade dos exames realizados.

6. Curva científica de assertividade por volume rotulado

A literatura empírica de Machine Learning supervisionado documenta uma **curva log-linear de saturação** entre volume de dados rotulados e desempenho do modelo. Para sistemas multimodais (Gemini, PaLM, Whisper), a relação aproximada é:

$$\kappa(N) \approx a + b \cdot \log_{10}(N)$$

Aplicada ao AIMEP com **Gemini 2.5 Flash Lite** + ground truth de **consenso de 3 examinadores** + iteração de prompt em cada faixa, a projeção é:

VÍDEOS ROTULADOS (CONSENSO 3 RATERS)	K PROJETADO	% CONCORDÂNCIA	FAIXA LANDIS & KOCH
1.000	~0,55	~78%	Moderate
5.000	~0,68	~84%	Substantial
10.000	~0,75	~87%	Substantial
30.000	~0,80	~89%	Almost perfect (limiar)
100.000	~0,82	~91%	Almost perfect
500.000+	~0,83 (saturado)	~91,5%	Saturação pelo κ -label

Interpretação: a partir de aproximadamente **30.000 vídeos rotulados por consenso**, o sistema entra na faixa "almost perfect" da tabela canônica de Landis & Koch (1977). Volumes acima desse patamar entregam ganho marginal próximo de zero — o investimento adicional de capital se converte em retorno inferior a +0,02 de κ por dobra de N.

6.1 Por que mais vídeos sozinhos não resolvem

Conforme Frénay & Verleysen (2014), o teto absoluto do κ é fixado pela qualidade interna do label. Se o consenso de 3 examinadores produz ground truth com κ -label $\approx 0,85$ entre os próprios raters, esse é o *limite duro* que nenhum modelo pode superar. Para passar de $\kappa 0,82$ para $\kappa 0,90$, seria necessário *aumentar o nível de consenso* (5+ raters), não o volume.

6.2 Por que iterar o prompt é essencial em paralelo

A curva da seção 6 pressupõe que o prompt está sendo iterado a cada faixa de volume — não basta acumular labels sem refinar o preset. A combinação de mais labels + iteração disciplinada é o que permite navegar a curva log-linear até a saturação.

7. Processo administrativo — três níveis com revisão humana obrigatória

O AIMEP **não substitui** o examinador, nem emite decisão administrativa autônoma. Toda detecção positiva que afete o veredito do candidato passa por revisão humana antes de qualquer ato. O fluxo opera em três níveis:

N0**Análise automatizada AIMEP — 100% dos exames**

Imediatamente após o upload do vídeo do exame, o AIMEP processa o conteúdo no Gemini 2.5 Flash Lite e gera o JSON estruturado: timestamps absolutos das infrações detectadas, descrição factual de cada ocorrência (incluindo aspas literais do áudio), nível de confiança, e veredito provisório baseado na rubrica CONTRAN 1.020/2025.

N1**Comitê de Análise — exames com processo administrativo aberto, em até 24h**

Para cada exame que motive abertura de processo administrativo (reprovação, recurso ou suspeita), o material é encaminhado em até 24 horas a um **Comitê de Análise N1**. Esse comitê executa **tripla análise comparativa**:

- **Análise do AIMEP** (JSON estruturado + descrições factuais).
- **Análise do examinador presencial** (relatório original do exame, gravações).
- **Análise independente do comitê** (revisão própria do vídeo + áudio).

O resultado da tripla análise é registrado em formato estruturado, com indicação clara de quais infrações têm consenso e quais apresentam divergência entre as três fontes.

N2**Análise Gerencial — decisão administrativa final**

Toda divergência identificada em N1 sobe para a **Análise Gerencial N2**, que atua como instância revisora final. Esse nível tem autoridade para:

- Determinar qual das três análises (AIMEP, examinador, comitê N1) é correta no caso específico.
- Dar seguimento ao processo administrativo com base na decisão consolidada.
- Identificar padrões sistemáticos de erro (do examinador, do AIMEP ou do comitê N1) e gerar recomendações de capacitação ou de ajuste de prompt do AIMEP.

Essa estrutura de três níveis garante que *nenhuma decisão administrativa* sobre o candidato é tomada sem revisão humana qualificada — o AIMEP é estritamente camada de triagem inteligente, jamais decisão final.

7.1 Por que falsos positivos do AIMEP não viram injustiça

Considerando precisão de 80% projetada no Cenário 3, dos ~24.000 flags positivos por mês:

- **~19.200 verdadeiros positivos** seguem para N1 e são confirmados pelo comitê.
- **~4.800 falsos positivos** são **integralmente capturados e descartados** em N1 antes de qualquer efeito sobre o candidato.
- **Probabilidade líquida de habilitação cancelada erroneamente: 0%**, porque todo flag positivo passa por validação humana antes de ato administrativo.

O erro residual do sistema integrado AIMEP + N1 + N2, considerando 95% de assertividade humana na revisão, é estatisticamente menor que **1%**.

7.2 Salvaguarda no nível do modelo — princípio "in dubio, não apontar"

Antes mesmo de chegar à revisão humana de N1, o sistema aplica uma **salvaguarda interna no nível do modelo de IA**: o princípio de conservadorismo ativo. Esta regra está codificada em dois pontos do pipeline (preset v25 e user prompt do backend) e é validada em *toda* chamada ao Gemini:

Princípio supremo do AIMEP: em qualquer dúvida sobre uma detecção, o modelo é *instruído* a **NÃO reportar** a infração. A regra "*in dubio pro reo*" da tradição jurídica brasileira é aplicada como instrução de inferência: na incerteza, o sistema NÃO acusa.

Critérios objetivos de não-deteção (codificados no preset)

CENÁRIO	DECISÃO DO AIMEP
Confiança numérica do modelo < 0,70	Omitir — não reportar como infração
Evidência apenas parcial em caso que exige correlação áudio+vídeo (cinto, motor calar, semáforo)	Omitir
Frame escuro, oclusão de quadrante ou áudio mascarado por ruído	Omitir
Possível comando autorizador do examinador no intervalo [t-3s, t+1s]	Omitir — assume autorização
Janela temporal imprecisa (> ±3 segundos)	Omitir — não inventar timestamp

Auditoria interna obrigatória do modelo antes de emitir resposta

O preset v25 instrui o modelo a executar uma *auto-verificação* antes de finalizar o JSON: para cada infração marcada como detectada, perguntar internamente:

"*Eu defenderia esta detecção em uma sessão presencial de auditoria, perante o examinador original e a comissão N1 do AIMEP, com vídeo e áudio rodando em loop?*"

Se a resposta for "*talvez não*" ou "*depende*", a instrução é **remover o item do array de infrações**. Essa auto-verificação opera *antes* da revisão humana — é uma camada extra de cautela.

Função de recompensa do benchmark interno

A iteração de prompt (descrita na seção 4.2) usa um critério explícito de função-recompensa:

- **O modelo é punido** no benchmark por: inflar confidence, reportar sem evidência sólida, inventar timestamps, ignorar comando potencialmente autorizador.
- **O modelo é recompensado** por: reportar apenas evidência clara e citável, omitir casos suspeitos sem prova sólida, errar para o lado da omissão em vez de errar para o lado da acusação.

Implicação prática — falsos positivos próximos de zero antes mesmo do N1

Com este princípio operando no nível do modelo, a estimativa de 80% de precisão usada nos cálculos das seções anteriores é uma estimativa *conservadora*. Em produção real, esperamos que a precisão final dos flags positivos seja substancialmente mais alta, porque o modelo já foi instruído a omitir casos duvidosos. O efeito esperado:

- Volume de flags positivos pode ser *menor* que a projeção bruta.
- Precisão dos flags emitidos é *maior*.
- Carga de trabalho do N1 é *menor e mais bem direcionada*.
- Falsos negativos (infrações que o modelo "deixou passar") são *capturados pelo examinador presencial original*, que permanece no fluxo do exame — preservando a função histórica do examinador como auditor de campo.

Em síntese: o AIMEP **multiplica a cobertura**, mas **nunca acusa sem evidência sólida**. A combinação dessa regra com os 3 níveis humanos (N0, N1, N2) torna o sistema *cientificamente robusto e juridicamente defensável*.

PARTE III DE III



Custos & Oportunidades

Investimento de calibração, custo fixo da infraestrutura, custo unitário em produção e a oportunidade do programa Google for Startups Cloud —
US\$ 350 mil em créditos para empresas de IA.

8. Custos consolidados

8.1 Custo de aprendizagem — investimento único

Nota cambial: os preços do Vertex AI são publicados oficialmente em **USD**. Para fins de planejamento, este documento adota câmbio referencial **USD/BRL = 5,00**. Custos de mão-de-obra brasileira (rotulagem) são primariamente em BRL, convertidos para USD pela mesma taxa para consistência. Variação cambial deve ser considerada nas projeções operacionais.

O investimento de calibração inicial do sistema é estimado em **US\$ 4.000**, distribuídos em:

ITEM	CUSTO (USD)	% DO TOTAL
Rotulagem de 10.000 vídeos por consenso de 3 examinadores DETRAN	US\$ 3.830	96%
Inferência Gemini 2.5 Flash Lite em modo batch nos 10.000 vídeos de calibração (US\$ 0,0084/vídeo)	US\$ 84	2%
Reserva técnica	US\$ 86	2%
Total do investimento de aprendizagem	US\$ 4.000	100%

A inferência durante a calibração é executada em *batch* (até 24h por lote, com 50% de desconto sobre o preço online padrão do Vertex), porque a calibração não tem requisito de latência — os resultados são comparados com o ground truth humano em ciclos de iteração de prompt que duram dias. Não há razão técnica para pagar inferência online padrão nesta fase.

Esse investimento é **único** — uma vez calibrado o sistema na fase inicial, a operação contínua opera com custos marginais.

8.2 Custo fixo de infraestrutura (servidor)

A infraestrutura computacional do AIMEP é dimensionada para operação *contínua, com alta disponibilidade e auditabilidade*. O processamento pesado (decodificação de vídeo, análise multimodal) ocorre nos servidores do Google Vertex AI — o servidor próprio executa orquestração, persistência de metadados, fila de processamento e geração de laudos PDF. A configuração abaixo segue padrão de produção pública, com banco gerenciado, redundância e backup automatizado:

COMPONENTE	ESPECIFICAÇÃO	CUSTO MENSAL
VM Compute Engine (orquestração)	e2-standard-4 (4 vCPU / 16 GB RAM)	US\$ 98/mês
Disco SSD persistente	100 GB pd-balanced	US\$ 10/mês
Cloud SQL Postgres gerenciado (com replica HA + backup automático)	db-custom-1-3840	US\$ 150/mês
Storage GCS (bucket aimep-prod com retenção longa)	~500 GB · CORS · lifecycle	US\$ 50/mês
Network egress (signed URLs de vídeos + PDFs)	~100 GB/mês saída	US\$ 40/mês
Cloud Monitoring + Logging	uptime check, alertas, retenção 30 dias	US\$ 50/mês
Backup automatizado off-site	snapshot diário do disco e do banco	US\$ 18/mês
Cloudflare (DNS, Tunnel, Access)	plano Free Tier para tunnel + Access	US\$ 0/mês
Reserva técnica (overhead Vertex/auxiliares)	buffer para flutuações	US\$ 39/mês
Custo fixo total da infraestrutura	—	US\$ 455/mês

Capacidade de processamento desta configuração: até **~300.000 vídeos/mês** em throughput sustentado, considerando a quota padrão de chamadas ao Vertex AI. O gargalo prático passa a ser a quota Vertex (que pode ser ampliada via solicitação ao Google), não a infraestrutura local. A configuração descrita atende, simultaneamente, várias operações regionais ou estaduais.

8.3 Custo por vídeo em produção — tempo vs custo

O custo unitário por vídeo em produção depende do **regime de processamento** escolhido. Quanto mais rápida a entrega, mais caro o vídeo. A tabela a seguir lista as opções viáveis (preços oficiais Vertex AI em USD):

REGIME	LATÊNCIA DE ENTREGA	MODELO	CUSTO/VÍDEO (USD)	CASO DE USO TÍPICO
Batch noturno	até 24h	Flash Lite (Vertex Batch — 50% off)	US\$ 0,0084	Auditoria geral massiva, sem urgência
Padrão	~5 minutos	Flash Lite (online standard)	US\$ 0,017	Operação diária do AIMEP
Prioridade alta	< 1 minuto	Flash Lite (online priority)	US\$ 0,024	Recursos administrativos urgentes
Express premium	< 30 segundos	Gemini 2.5 Pro Preview	US\$ 0,24	Casos eliminatórios / segunda opinião

Custos calculados sobre vídeo médio de 8 minutos · 1 fps default · áudio nativo · ~150k tokens input + ~4k tokens output.
Câmbio referencial USD/BRL = 5,00.

9. Oportunidade — Google for Startups Cloud Program (tier IA)

O Google opera, desde 2024 com tier dedicado a IA, o programa *Google for Startups Cloud*. A análise preliminar dos critérios de elegibilidade indica que o projeto AIMEP **se enquadra integralmente** no perfil de empresa-alvo do programa. Em caso de aceitação, o programa fornece créditos de produção que cobrem integralmente a operação contínua do sistema durante 24 meses.

9.1 Pacote de benefícios disponível (tier Scale + AI)

BENEFÍCIO	VALOR (USD)
Créditos Google Cloud (Scale tier base)	US\$ 100.000
Crédito adicional para AI Startups	US\$ 250.000
Specialist Support (engenheiros Google Cloud)	US\$ 12.000
Total potencial	US\$ 362.000
Duração dos créditos	24 meses a partir da aprovação

9.2 Análise preliminar de elegibilidade do AIMEP

Os critérios oficiais publicados pelo programa, e a posição do AIMEP em cada um deles, são:

CRITÉRIO OFICIAL	REGRA	AIMEP ATENDE?
Empresa privada formalmente constituída	CNPJ ativo	⚠ <i>Confirmar formalização</i>
Sede em país elegível	Brasil é elegível desde 2021	✅ Sim
Idade da empresa	< 10 anos desde a fundação	✅ Sim
Equity funding levantado	< US\$ 20 milhões	✅ Sim
Empresa privada (não-listada)	Não pode estar em bolsa	✅ Sim
IA como tecnologia central	Para o tier AI: produto principal usa AI/ML	✅ Sim — núcleo é Vertex Gemini Flash Lite
Endosso de partner (tier Scale)	VC, aceleradora ou incubadora parceira do Google	⚠ <i>Confirmar endosso</i>
Não usar créditos para revenda	Cripto-mining, hosting de revenda, etc.	✅ Sim

9.3 Itens críticos a confirmar antes da aplicação formal

- 1. **Formalização do CNPJ** da empresa AIMEP. O programa exige entidade legal ativa — qualquer formato registrado (MEI, LTDA, S/A) atende.
- 2. **Endosso de partner** oficial. Lista de partners brasileiros aceitos: aceleradoras (ACE, Distrito, Endeavor, BlueLab), VCs (Astella, Canary, Igah, Maya Capital, Kaszek, Monashees, redpoint eventures), incubadoras universitárias (CIETEC USP, INOVA UNICAMP, Esalq Tec, Cubo Itaú).
- 3. **Pitch deck** com problema, solução, tração técnica (este documento serve como evidência), time, mercado endereçável.

Posição estratégica do AIMEP

O programa Google for Startups Cloud é uma **oportunidade sem cláusulas de exclusividade**: aceitar os créditos não amarra o AIMEP ao Vertex AI. A arquitetura técnica do sistema mantém abstração multi-backend (VertexBackend, ClaudeBackend, QwenBackend) — em cenário hipotético de descontinuação ou aumento de preço, a migração custa entre 2 e 4 semanas de engenharia.

A combinação de (a) operação **US\$ 0,0084–0,017 por vídeo**, (b) custo fixo de servidor **US\$ 455/mês**, (c) investimento de aprendizagem **US\$ 4.000**, e (d) **US\$ 362.000 em créditos GCP** potencialmente disponíveis, constitui um caso de viabilidade econômica de implementação imediata.

10. Conclusão e próximos passos

Os dados consolidados deste estudo demonstram, com base em literatura científica peer-reviewed (Cohen 1960; Landis & Koch 1977; Allsbrook et al. 2001; Regier et al. 2013; Frénay & Verleysen 2014; Kahneman et al. 2021) e em precificação pública vigente do Google Vertex AI, que o AIMEP entrega:

1. **Aumento de cobertura efetiva da auditoria de exames práticos de aproximadamente 4 vezes** — de ~22,5% (operação humana atual com 30% dos exames auditados) para ~89% (AIMEP analisando 100% dos exames com Gemini 2.5 Flash Lite + consenso de 3 raters como ground truth).
2. **Diferencial técnico irreproduzível em pipelines com frame extraction** — análise nativa de vídeo + áudio em chamada única, capturando correlações áudio-visuais essenciais para infrações como cinto, motor calado e comandos verbais do examinador.
3. **Aumento substancial da capacidade de detecção** de irregularidades que a operação atual, restrita a ~30% dos exames, deixa passar — proporcionalmente equivalente ao multiplicador de cobertura de aproximadamente 4x demonstrado na seção 5.
4. **Processo administrativo de 3 níveis** (AIMEP → Comitê N1 24h → Análise Gerencial N2) que mantém **revisão humana obrigatória** antes de qualquer ato administrativo, garantindo que falsos positivos do sistema sejam capturados antes de afetar o candidato.
5. **Caminho científico claro para $\kappa \approx 0,80$** via curva log-linear de saturação — atingível com aproximadamente 30.000 vídeos rotulados por consenso, em 4–6 meses de operação iterativa.
6. **Investimento de calibração contido em US\$ 4.000**, infraestrutura mensal em US\$ 455, custo unitário de produção em US\$ 0,0084–0,017 (batch a online padrão), com possibilidade de operação 24 meses gratuita via programa Google for Startups Cloud (US\$ 350k em créditos).

10.1 Próximos passos recomendados

1. **Formalização do CNPJ** e levantamento de endosso de partner para aplicação no Google for Startups Cloud (prazo estimado: 4 semanas).
2. **Calibração inicial** com 10.000 vídeos rotulados por consenso + iteração de prompt (prazo estimado: 8 semanas).
3. **Validação empírica gate-1** em 1.000 vídeos brasileiros — meta: $\kappa \geq 0,70$ antes de produção plena (prazo estimado: 4 semanas após calibração).
4. **Implantação do processo administrativo de 3 níveis** com órgãos DETRAN piloto (prazo estimado: 12 semanas em paralelo).
5. **Operação plena em produção** com revisão trimestral de assertividade e iteração contínua de prompt.

11. Referências bibliográficas

Todas as referências abaixo são **peer-reviewed ou oficiais**, com link verificável (DOI, PubMed, Google Scholar ou URL oficial). Acessadas em 05 de maio de 2026.

Concordância entre raters (kappa) — fundamentação metodológica

1. Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46.
DOI: [10.1177/001316446002000104](https://doi.org/10.1177/001316446002000104)
2. Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174.
DOI: [10.2307/2529310](https://doi.org/10.2307/2529310) · PubMed: [843571](https://pubmed.ncbi.nlm.nih.gov/843571/)
3. McHugh, M. L. (2012). Interrater reliability: the kappa statistic. *Biochemia Medica*, 22(3), 276–282.
PMC (acesso aberto): [PMC3900052](https://pubmed.ncbi.nlm.nih.gov/PMC3900052/)
4. Hallgren, K. A. (2012). Computing inter-rater reliability for observational data: an overview and tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34.
PMC (acesso aberto): [PMC3402032](https://pubmed.ncbi.nlm.nih.gov/PMC3402032/)
5. Fleiss, J. L., Levin, B., & Paik, M. C. (2003). *Statistical Methods for Rates and Proportions*, 3rd ed. Wiley. (Capítulo 18 — método clássico para variância do κ e convergência com volume.)
Editora: [Wiley](https://www.wiley.com/)

Tetos empíricos de IRR — apenas papers que reportam κ explicitamente

1. Allsbrook, W. C. Jr., Mangold, K. A., Johnson, M. H., Lane, R. B., Lane, C. G., & Epstein, J. I. (2001). Interobserver reproducibility of Gleason grading of prostatic carcinoma: general pathologists. *Human Pathology*, 32(1), 81–88. **κ overall = 0,435 (38 casos).**
DOI: [10.1053/hupa.2001.21135](https://doi.org/10.1053/hupa.2001.21135) · PubMed: [11172299](https://pubmed.ncbi.nlm.nih.gov/11172299/)
2. Regier, D. A., Narrow, W. E., Clarke, D. E., Kraemer, H. C., Kuramoto, S. J., Kuhl, E. A., & Kupfer, D. J. (2013). DSM-5 field trials in the United States and Canada, Part II: test-retest reliability of selected categorical diagnoses. *American Journal of Psychiatry*, 170(1), 59–70. **$\kappa < 0,20$ a $0,79$ por diagnóstico.**
DOI: [10.1176/appi.ajp.2012.12070999](https://doi.org/10.1176/appi.ajp.2012.12070999) · PubMed: [23111466](https://pubmed.ncbi.nlm.nih.gov/23111466/)

Ruído de julgamento humano e label noise em Machine Learning

1. Frénay, B., & Verleysen, M. (2014). Classification in the presence of label noise: a survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5), 845–869.
DOI: [10.1109/TNNLS.2013.2292894](https://doi.org/10.1109/TNNLS.2013.2292894)
2. Kahneman, D., Sibony, O., & Sunstein, C. R. (2021). *Noise: A Flaw in Human Judgment*. Little, Brown Spark.
ISBN-13: 978-0316451406 · Editora: [Little, Brown](https://www.littlebrown.com/)

Documentação oficial Google e regulação CONTRAN

1. Google Cloud (2026). *Vertex AI Generative AI Pricing*. Documentação oficial — preços por token de modelos Gemini.
URL: cloud.google.com/vertex-ai/generative-ai/pricing
2. Google for Startups (2024–2026). *Google for Startups Cloud Program — overview, AI tier, eligibility*.
Programa: cloud.google.com/startup · AI tier: cloud.google.com/startup/ai · Aplicação: cloud.google.com/startup/apply
3. CONTRAN — Conselho Nacional de Trânsito (2025). *Resolução nº 1.020/2025 — procedimentos para realização do exame de direção veicular para obtenção e renovação da CNH*.
Texto oficial: gov.br/transportes/.../conteudo-contran/resolucoes

Documentação técnica do projeto AIMEP (interna)

1. AIMEP (2026). *docs/gemini_vertex_setup.md* — guia interno de autenticação Vertex AI e modelos validados. Repositório do projeto.
2. AIMEP (2026). *tooling/bench_demo/presets/v25/aimep-r1-vip-v25.md* — preset de prompt v25 (multi-câmera VIP/ HIK + áudio nativo). Repositório do projeto.

Critério de inclusão das referências: esta lista contém **apenas** publicações cuja existência foi verificada via PubMed/DOI/URL oficial e cujo conteúdo específico citado neste documento foi confirmado caso a caso. Referências sobre on-road driving assessment não foram incluídas porque a literatura internacional consultada não reporta explicitamente o coeficiente kappa de Cohen para examinadores de exame prático sob protocolos comparáveis ao brasileiro — afirmar números sem suporte direto seria inadequado para um documento técnico-científico destinado a edital de modernização pública.